

## Применение методов машинного обучения в задаче улучшения разрешения снимков, полученных со спутника\*

*Белозерцев А. О.<sup>1</sup>, Воскресенский Н. Д.<sup>1</sup>, Грибова О. Б.<sup>1</sup>, Казаков А. А.<sup>1</sup>,  
Мурзаев Я. А.<sup>1</sup>, Хохлов А. А.<sup>1</sup>, Шабалина А. А.<sup>1</sup>*  
author@site.ru

<sup>1</sup>Московский физико-технический институт (государственный университет); <sup>2</sup>Организация

Данная работа посвящена исследованию вопроса повышения разрешения мультиспектральных изображений. Рассмотрены разные метрики оценки качества улучшения пространственного разрешения изображений, показана энтропия изображения как идентификатор потерь информации и ее корреляция с преобразованием над изображением. Предложены подход для анализа изображений, алгоритм повышения разрешения путем использования опорных изображений, метод оптимизации параметров данного алгоритма. Проведен сравнительный анализ с аналогичными подходами. Найдены условия максимизации энтропии восстановленного изображения.

**Ключевые слова:** *ключевое слово, ключевое слово, еще ключевые слова, еще еще ключевое слово.*

## Entropy maximization in an image various types of transformations\*

*Belozertsev A. O.<sup>1</sup>, Voskresenskiy N. D.<sup>1</sup>, Gribova O. B.<sup>1</sup>, Kazakov A. A.<sup>1</sup>,  
Murzaev Y. A.<sup>1</sup>, Khokhlov A. A.<sup>1</sup>, Shabalina A. A.<sup>1</sup>*

<sup>1</sup>Moscow Institute of Physics and Technology (State University); <sup>2</sup>Organization

English abstract.

**Keywords:** *keyword, keyword, more keywords, moooooore keywords.*

### Введение

Основной целью данной работы является разработка алгоритма повышения пространственного разрешения мультиспектральных изображений и изображений с узким диапазоном частот.

Предметом исследования являются изображения с различным набором частот, имеющие низкое пространственное разрешение, а также панхроматические и RGB-изображения.

В настоящее время аэрокосмическая съемка является основным инструментом для исследований в таких областях как георазведка, метеопрогнозирование, картография, экологический мониторинг и др. При работе со снимками поверхности земли наиболее острой является проблема низкого разрешения полученных трехканальных (RGB) и узкоспектральных изображений, влекущая за собой потерю информативности. Решению задачи повышения качества снимков и посвящена данная работа.

Потребность в получении снимков высокого качества возникает при анализе изображений для распознавания объектов [1], при мониторинге территорий на основе аэрокос-

---

Научный руководитель: Стрижов В. В. Задачу поставил: Матвеев И. А. Консультант: Консультант И. О.

мических данных в аграрной [2] и нефтегазовой [3] отраслях, для регистрации и прогнозирования морского волнения [4, 5]. Кроме того, повышение разрешения снимка может использоваться для повышения точности навигации летательных аппаратов [6, 7].

Для решения задачи улучшения качества снимков поверхности земли предлагается использовать методы машинного обучения, в частности нейронные сети.

В работе [8] изложен вероятностный алгоритм повышения разрешения мультиспектрального изображения при помощи опорного снимка в виде панхроматического изображения более высокого качества. В [9, 10] предложены методы улучшения качества, построенные на экстраполяции или объединении пространственных спектров.

Одним из основных преимуществ представленного решения является использование универсального метода - нейронной сети, который позволяет достичь высоких результатов. Однако, данный алгоритм имеет ряд недостатков, среди которых можно отметить отсутствие его физической интерпретации, а также необходимость наличия больших вычислительных мощностей для реализации.

Целью представленного эксперимента является создание модели нейронной сети, которая смогла бы увеличить пространственное разрешение лучше имеющихся на данный момент аналогов, основанных на аналитических подходах. В качестве данных использовались снимки с космических спутников.

В работе [11] предлагается метод, представляющий собой восстановление изображения с помощью последовательного применения Direct deconvolution и MLPs («Multi layer perceptrons»).

В статье [12] метод MLPs сравнивается с методом BM3D. Сравнение показывает приблизительно одинаковые результаты (PSNR 30dB).

В работе [13] применяется метод, который состоит в последовательном применении трех конволюций с разными параметрами. Эксперимент проведен как с тремя каналами (RGB), так и с одним. Данная работа на момент 2015-2016 года является лучшей по двум параметрам: скорость и качество. В качестве метрики сравнения берется PSNR - пиковое отношение сигнал/шум.

В работе [14] используется сравнивается две различных функции потерь, одна из которых уже упомянутая выше PSNR, а вторая использует один из слоев сверточной сети. Для работы последнего способа используется предобученная сеть VGG-16, что дает выигрыш в скорости, так как нет надобности в ее обучении на каждой итерации.

## Обозначения

Введем следующие обозначения:

- $x$  – исходное изображение
- $y$  – изображение с пониженным разрешением, полученное некоторым преобразованием из  $x$ .  $y$  подается на вход алгоритма.
- $z$  – изображение с повышенным разрешением на выходе алгоритма
- $x(i, j)$  – пиксель под номером  $(i, j)$  изображения  $x$
- $MAX_x$  – пиксель максимальной яркости в изображении  $x$

## Постановка задачи

Пусть дано некоторое изображение плохого качества (с недостаточным разрешением). Необходимо представить метод увеличения разрешения изображения  $y$  (размера  $m \times n$ ), результат которого превосходит результаты методов, представленных в литературе. В качестве метрики качества работы алгоритма выберем PSNR для удобства сравнения с су-

ществующими методами.

$$MSE = \frac{1}{mn} \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} [x(i, j) - z(i, j)]^2 \quad (1)$$


$$PSNR = 10 \lg \left( \frac{MAX_x^2}{MSE} \right) \quad (2)$$

## Описание алгоритма

В данной работе рассматривались два подхода к решению задачи восстановления изображения.

На начальном этапе моделирования использовалась линейная нейронная сеть, состоящая из девяти слоев. Для обучения были использованы изображения размера  $30 \times 30$  пикселей в общем количестве около 2700 образцов, полученные разделением изображения  $1560 \times 1560$ . Ухудшение изображения проводилось усреднением областей  $3 \times 3$ , итоговое изображение имело размер  $10 \times 10$  пикселей.

Ухудшенное изображение подавалось на вход сети. После каждого линейного слоя размер изображения увеличивался на 100 пикселей. В качестве нелинейной функции активации между каждым слоем использовалась ReLu. Она равна нулю, если на вход ей подается отрицательное значение, следовательно, все выходы последнего слоя, имеющие отрицательное значение, на итоговой картинке будут выглядеть как битые пиксели. С целью решения данной проблемы на в конце выполнялось увеличение размера изображения с 900 до 3600 пикселей с целью проведения последующего усреднения. Результаты обработки представлены на рисунке 1.




**Рис. 1.** Линейная нейронная сеть (слева на право: оригинал, ухудшено, результат)

На восстановленном изображении видны швы, их наличие связано с независимостью исходных изображений друг от друга. Кроме того, данная сетка обладает высоким риском переобучения из-за большого числа параметров сети, в сравнении с объемом данных. В связи с этим было решено прекратить разработку данного алгоритма.

На втором этапе моделирования мы пересмотрели принцип формирования набора исходных данных и для создания обучающей выборки были взяты области  $9 \times 9$  пикселей, из которой, путем усреднения областей  $3 \times 3$ , получалась матрица  $3 \times 3$ . После данной процедуры производился сдвиг на 3 пикселя, и процедура повторялась. В основе данного решения лежит идея того, что на значение пикселя влияют лишь его близлежащие соседи, которые могут содержать в себе информацию о том же объекте, что и в целевом пикселе.

Поэтому наиболее значимой для восстановления одного пикселя, полученного усреднением квадрата  $3 \times 3$  пикселей, является область  $4 \times 4$ . Однако, граничные пиксели являются элементами соседних квадратов  $3 \times 3$ , которые так же подверглись усреднению, что вынуждает брать для обучения всю область  $9 \times 9$  или что тоже самое  $3 \times 3$  в усредненном формате.

Для ухудшенного изображения  $3 \times 3$  производилась билинейная интерполяция с целью увеличения размера изображения до размера  $9 \times 9$ . После чего интерполированное изображение подвергается процедуре восстановления изображения. Она состоит из применения 9 различных конволюций к центральной области  $4 \times 4$ . Каждая конволюция имеет ядро размером  $3 \times 3$ , обучение которого происходит независимо от остальных. Итого, необходимо подобрать 81 параметр, тогда как общее количество образцов в одной картинке порядка 270 000. Таким образом мы устраним риск переобучиться. Результат применения данного алгоритма показан на рисунке 2.



**Рис. 2.** 9 независимых конволюций (слева на право: оригинал, ухудшено, результат)

## Вывод

Подводя итоги можно добавить, что результаты, полученные последней моделью, были сравнены с результатом билинейной интерполяции. Аналогичное сравнение альтернативных методов восстановления изображений было приведено в работах [13, 14]. В качестве метрики использовали MSE, так как в большинстве статей [11, 12, 14] утверждается наличие обратнопропорциональной зависимости от PSNR. Данное сравнение показало уменьшение значения MSE в 3 раза относительно билинейной интерполяции. Это, а также и визуальная оценка полученных изображений позволяет утверждать о положительном результате описанного способа улучшения качества изображения.

## Литература

- [1] Ю.В. Визильтер and С.Ю. Желтов. Использование проективных морфологий в задачах обнаружения и идентификации объектов на изображениях. *Известия Российской академии наук. Теория и системы управления*, (2):125–138, 2009.
- [2] Alexander Murynin, Konstantin Gorokhovskiy, Valery Bondur, and Vladimir Ignatiev. Analysis of large long-term remote sensing image sequence for agricultural yield forecasting. In *Image Mining. Theory and Applications. Proceedings of the 4th International Workshop on Image Mining. Barcelona, Spain*, pages 48–55, 2013.
- [3] В.Г. Бондур. Аэрокосмический мониторинг объектов нефтегазового комплекса. *Исследование Земли из космоса*, (2):84–84, 2012.

- [4] В.Г. Бондур, В.А. Дулов, А.Б. Мурынин, and В.Ю. Игнатъев. Восстановление спектров морского волнения по спектрам космических изображений в широком диапазоне частот. *Известия Российской академии наук. Физика атмосферы и океана*, 52(6):716–728, 2016.
- [5] В.Г. Бондур, А.Б. Мурынин, and В.Ю. Игнатъев. Оптимальный выбор параметров для восстановления спектров морского волнения по аэрокосмическим изображениям. *Машинное обучение и анализ данных*, 2(2):218–230, 2016.
- [6] А.А. Ишутин, И.С. Кикин, Г.Г. Себряков, and В.Н. Сошников. Алгоритмы обнаружения, локализации и распознавания оптико-электронных изображений группы изолированных наземных объектов для инерциально-визирных систем навигации и наведения летательных аппаратов. *Известия Российской академии наук. Теория и системы управления*, (2):85–85, 2016.
- [7] Ю.В. Визильтер, О.В. Выголов, С.Ю. Желтов, and А.Ю. Рубис. Комплексирование многоспектральных изображений для систем улучшенного видения на основе методов диффузной морфологии. *Известия Российской академии наук. Теория и системы управления*, (4):103–114, 2016.
- [8] К.Ю. Гороховский, В.Ю. Игнатъев, А.Б. Мурынин, and К.О. Ракова. Поиск оптимальных параметров вероятностного алгоритма повышения пространственного разрешения мультиспектральных спутниковых изображений. *Известия Российской академии наук. Теория и системы управления*, (6):112–124, 2017.
- [9] А.А. Гурченков, В.Г. Бочкарева, А.Б. Мурынин, and А.Н. Трёкин. Улучшение качества изображений методом экстраполяции пространственных спектров. *Вестник Московского государственного технического университета им. НЭ Баумана. Серия «Естественные науки»*, (2 (65)), 2016.
- [10] В.Г. Бочкарева, И.А. Матвеев, А.Б. Мурынин, and Цурков В.И. Методы улучшения качества изображений, основанные на пространственном спектральном анализе. *Известия Российской академии наук. Теория и системы управления*, (6):62–70, 2015.
- [11] Christian J Schuler, Harold Christopher Burger, Stefan Harmeling, and Bernhard Scholkopf. A machine learning approach for non-blind image deconvolution. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 1067–1074, 2013.
- [12] Harold C Burger, Christian J Schuler, and Stefan Harmeling. Image denoising: Can plain neural networks compete with bm3d? In *Computer Vision and Pattern Recognition (CVPR), 2012 IEEE Conference on*, pages 2392–2399. IEEE, 2012.
- [13] Chao Dong, Chen Change Loy, Kaiming He, and Xiaoou Tang. Image super-resolution using deep convolutional networks. *IEEE transactions on pattern analysis and machine intelligence*, 38(2):295–307, 2016.
- [14] Justin Johnson, Alexandre Alahi, and Li Fei-Fei. Perceptual losses for real-time style transfer and super-resolution. In *European Conference on Computer Vision*, pages 694–711. Springer, 2016.